1. GİRİŞ VE AMAÇ

1.1. Projenin Önemi

Beyin tümörleri, dünya genelinde kansere bağlı ölümlerin önemli nedenlerinden biridir. Erken teşhis, hastaların hayatta kalma oranını ve tedavi başarısını doğrudan etkileyen en kritik faktördür. Günümüzde teşhis yöntemi olarak manyetik rezonans görüntüleme (MR) yaygın olarak kullanılmaktadır. Ancak, bu görüntülerin radyologlar tarafından manuel olarak incelenmesi zaman alıcıdır ve insan gözünün yorgunluğuna bağlı olarak hatalı teşhis riskini barındırır. Bu bağlamda, yapay zeka ve derin öğrenme tekniklerinin kullanımı, radyologlara yardımcı olacak bir "Karar Destek Sistemi" olarak hayati önem taşımaktadır.

1.2. Projenin Amacı

Bu projenin temel amacı, farklı beyin tümörü sınıflarını (Glioma, Meningioma ve Genel Tümör) MR görüntüleri üzerinden otomatik ve yüksek doğrulukla tespit edebilen bir sistem geliştirmektir. Proje kapsamında tek bir modele bağlı kalınmamış; hem kendi tasarladığımız özgün (Custom) mimariler hem de literatürde başarısı kanıtlanmış Transfer Learning modelleri (VGG, ResNet, MobileNet vb.) karşılaştırmalı olarak analiz edilmiştir.

---

2. VERİ SETİ

Çalışmada kullanılan veri seti, beyin MR görüntülerinden oluşmaktadır. Veri seti, modelin öğrenmesini sağlamak amacıyla üç temel sınıfa ayrılmıştır: Glioma, Meningioma ve Brain Tumor.

Görüntüler işleme alınmadan önce ön işleme (preprocessing) adımlarına tabi tutulmuştur. Tüm görüntüler, derin öğrenme modellerinin giriş katmanlarına uygun olacak şekilde 224x224 piksel boyutlarına yeniden boyutlandırılmış ve piksel değerleri 0-1 aralığına sıkıştırılarak normalizasyon (1/255) işlemi uygulanmıştır. Veri seti, %80 Eğitim ve %20 Test (Doğrulama) olarak ikiye ayrılmıştır.

3. MATERYAL VE YÖNTEM

Bu çalışmada, görüntü sınıflandırma problemlerinde en başarılı yöntem olarak kabul edilen Evrişimli Sinir Ağları (CNN) kullanılmıştır. Projenin genel işleyiş adımları aşağıdaki akış şemasında gösterilmiştir.

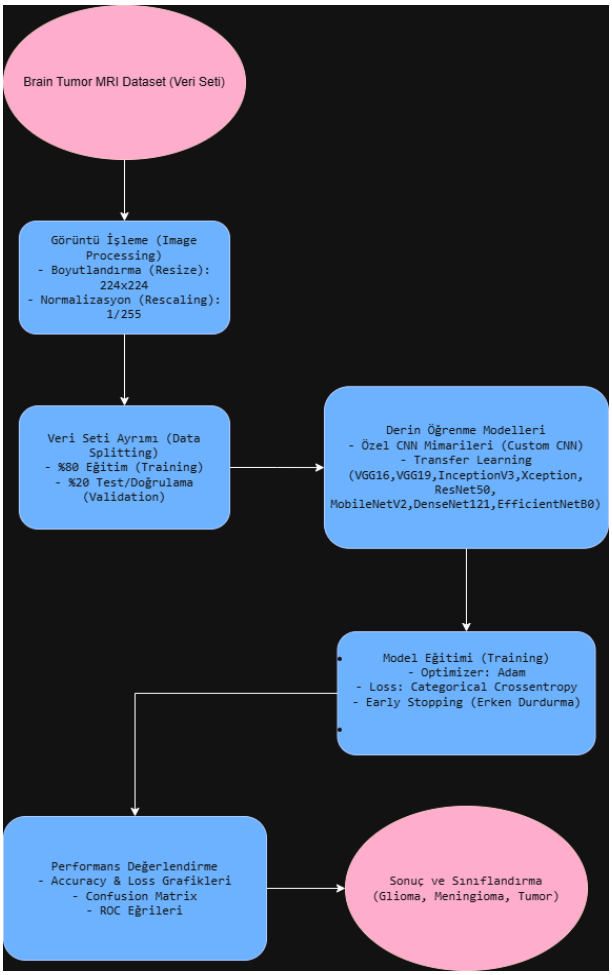

3.1. Kullanılan Yöntemler

Projede iki ana yaklaşım benimsenmiştir:

1. Özgün (Custom) Modeller: Katmanları tarafımızca belirlenen, sığ (Simple) ve derin (Deep) olmak üzere iki farklı CNN mimarisi tasarlanmıştır.
2. Transfer Learning: ImageNet veri setinde eğitilmiş hazır modellerin ağırlıkları kullanılarak VGG16, VGG19, ResNet50, MobileNetV2, InceptionV3, Xception, DenseNet121 ve EfficientNetB0 modelleri projeye uyarlanmıştır.

3.2. Eğitim Parametreleri

Tüm modellerin eğitiminde Adam optimizasyon algoritması ve Categorical Crossentropy hata fonksiyonu kullanılmıştır. Aşırı öğrenmeyi (Overfitting) engellemek amacıyla Early Stopping (Erken Durdurma) mekanizması uygulanmıştır.

---

4. BULGULAR VE TARTIŞMA

Bu bölümde, eğitilen 10 farklı modelin performans analizleri; Accuracy-Loss grafikleri, Confusion Matrix ve ROC Eğrileri üzerinden ayrı ayrı incelenmiştir.

4.1. Custom_CNN_Simple Modeli

Tasarladığımız sığ mimarili bu model, temel özelliklerin öğrenilmesindeki başarımı test etmek için kullanılmıştır.

- 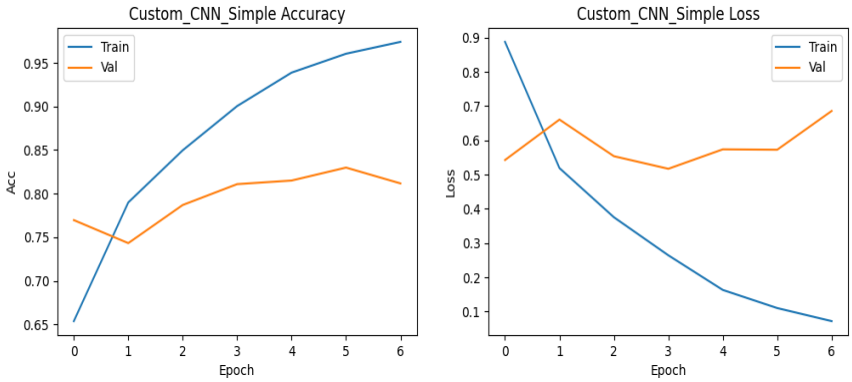

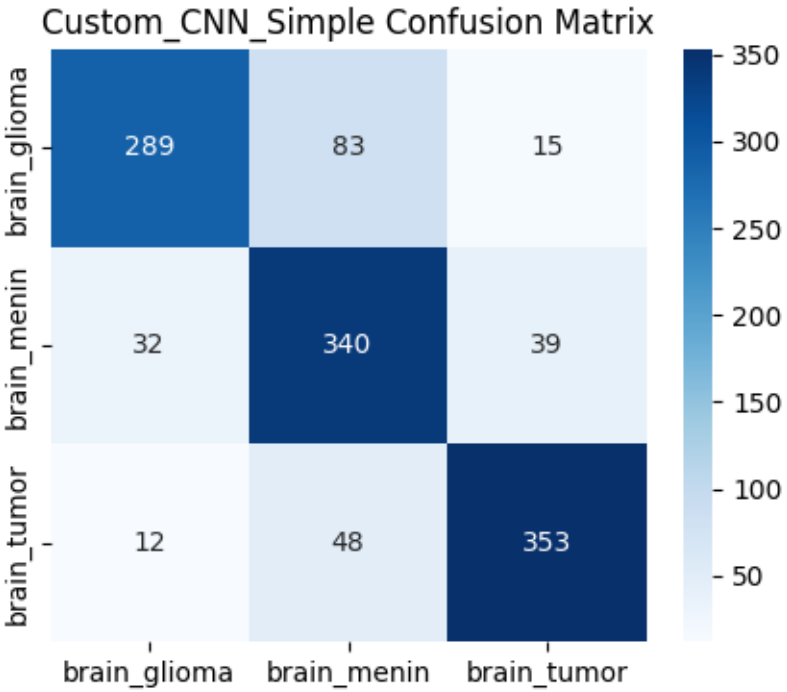

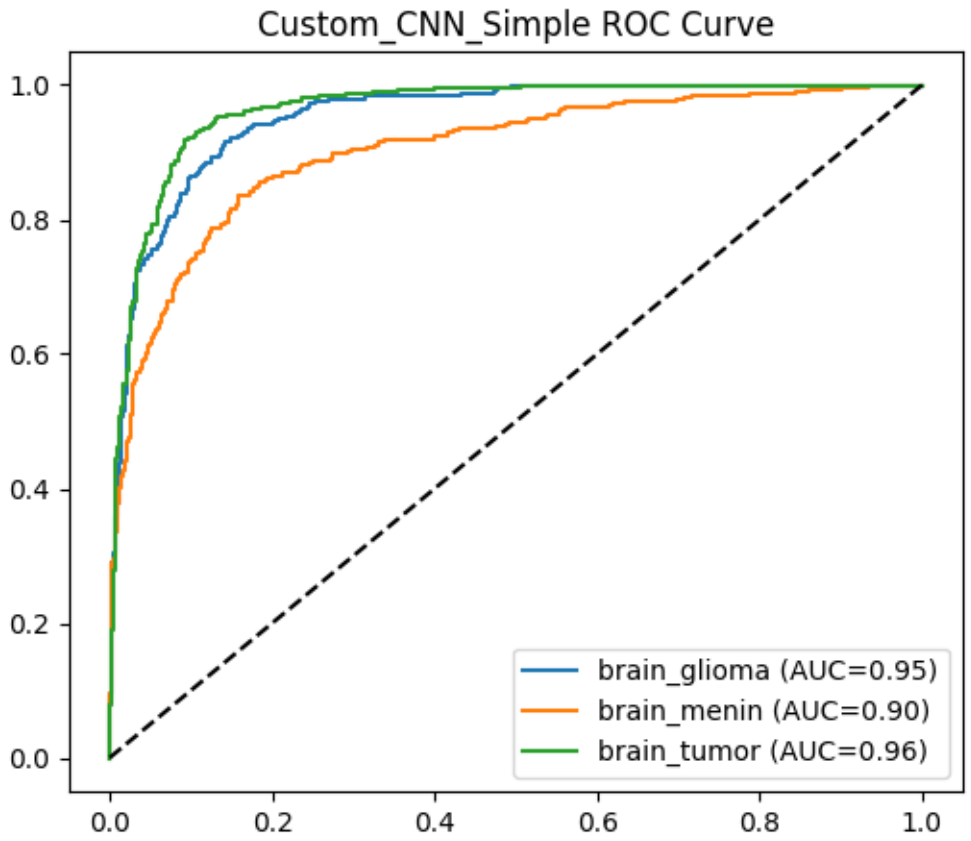

Değerlendirme: Model, basit yapısına rağmen öğrenme eğiliminde bulunmuş, ancak karmaşık dokuları ayırt etmede derin modellere kıyasla daha sınırlı kalmıştır. Temel bir referans (baseline) noktası oluşturmuştur.

4.2. Custom_CNN_Deep Modeli

Simple modelin katman sayısı artırılarak elde edilen bu özgün derin mimari, daha detaylı öznitelik çıkarımı hedeflemiştir.

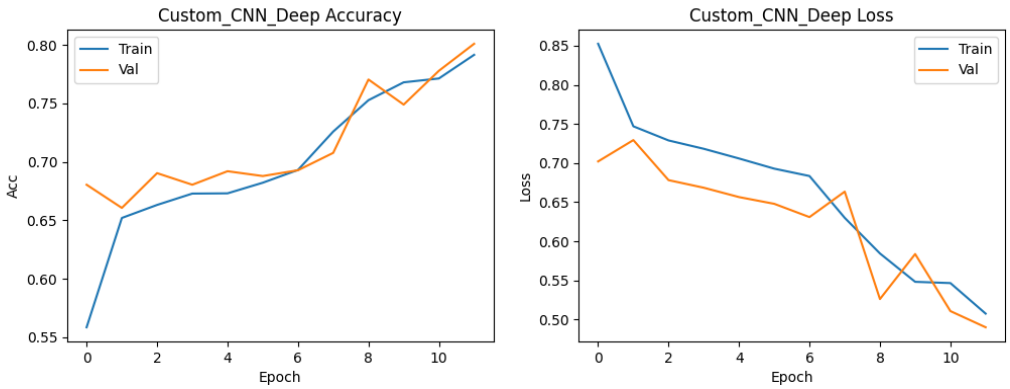

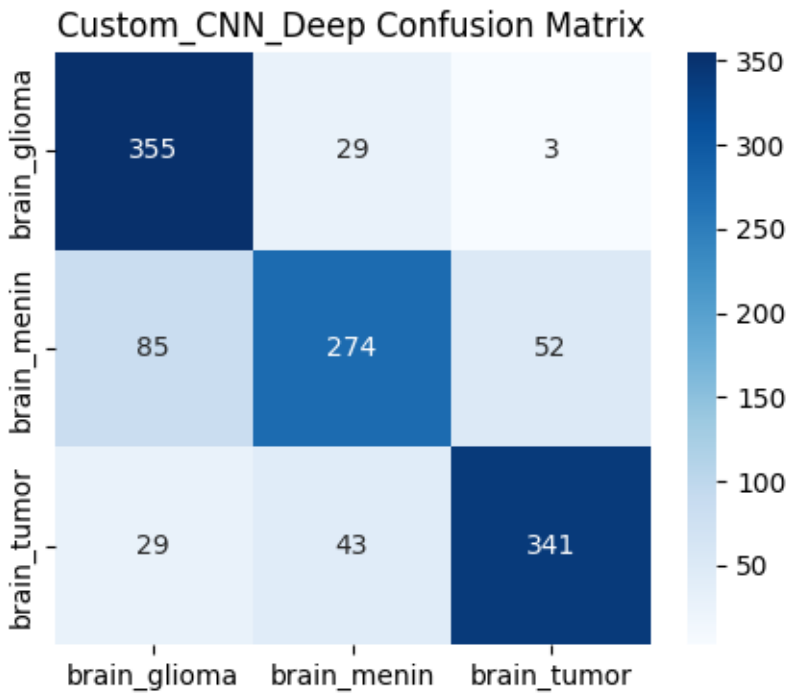

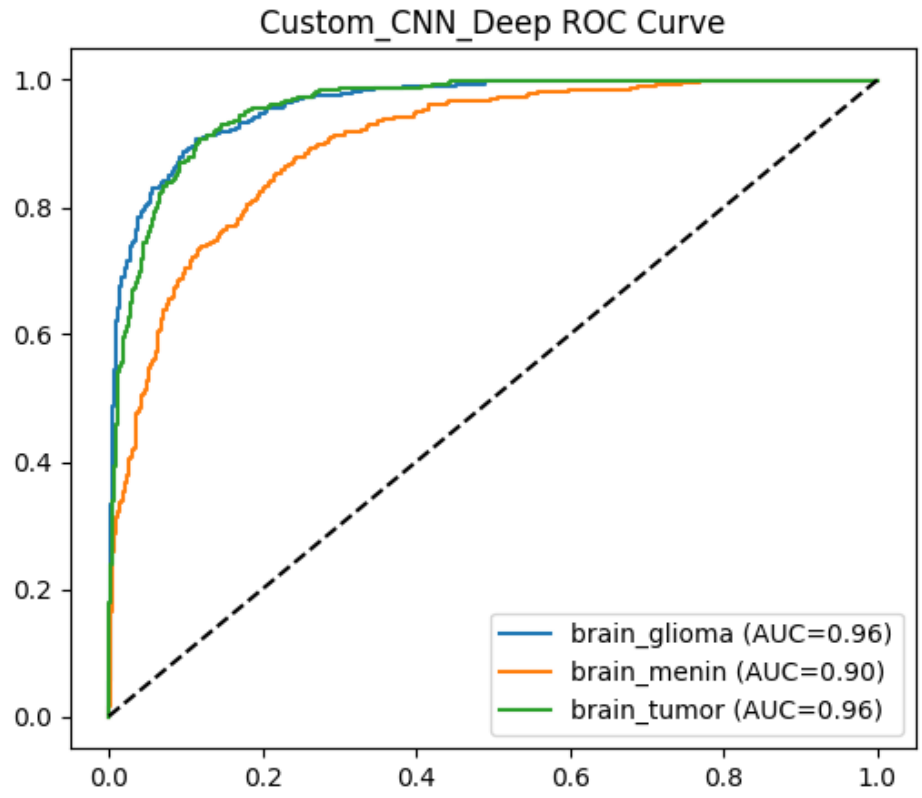

- Değerlendirme: Derinleştirilmiş yapı sayesinde eğitim ve doğrulama başarısı artış göstermiştir. Özgün bir mimari ile de başarılı sonuçlar alınabileceği görülmüştür.

4.3. VGG16 Modeli

Klasik derin öğrenme mimarilerinden olan VGG16, güçlü özellik çıkarımı yeteneği ile test edilmiştir.

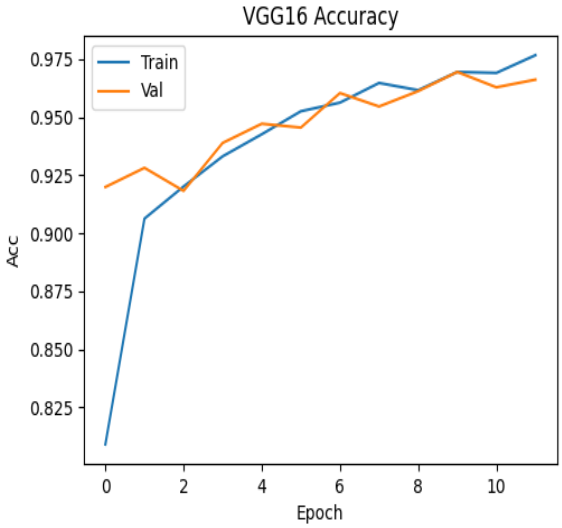

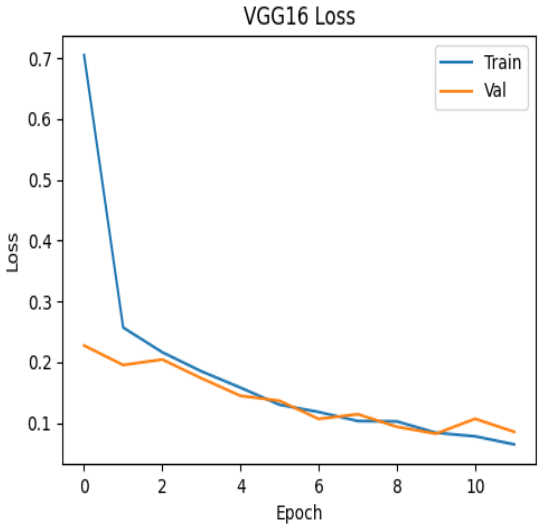

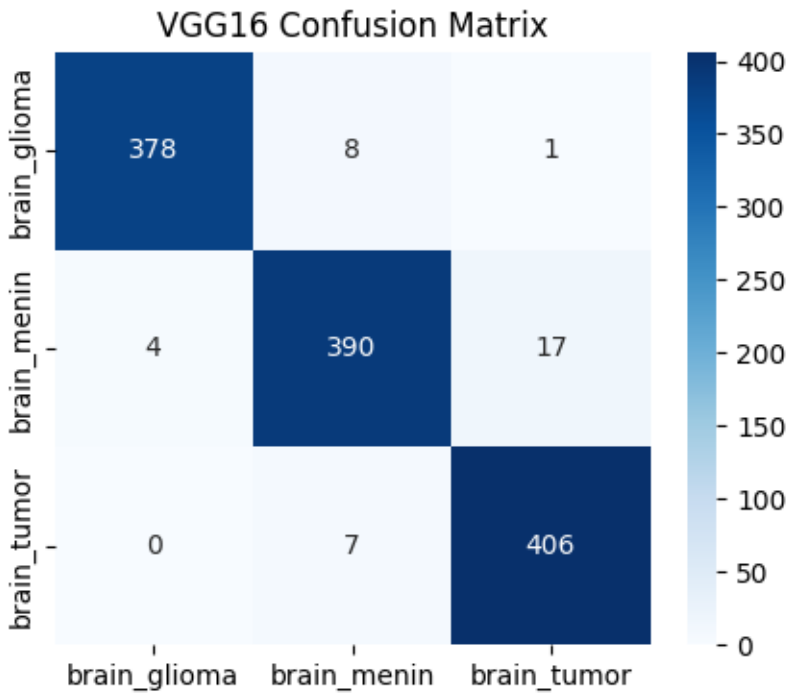

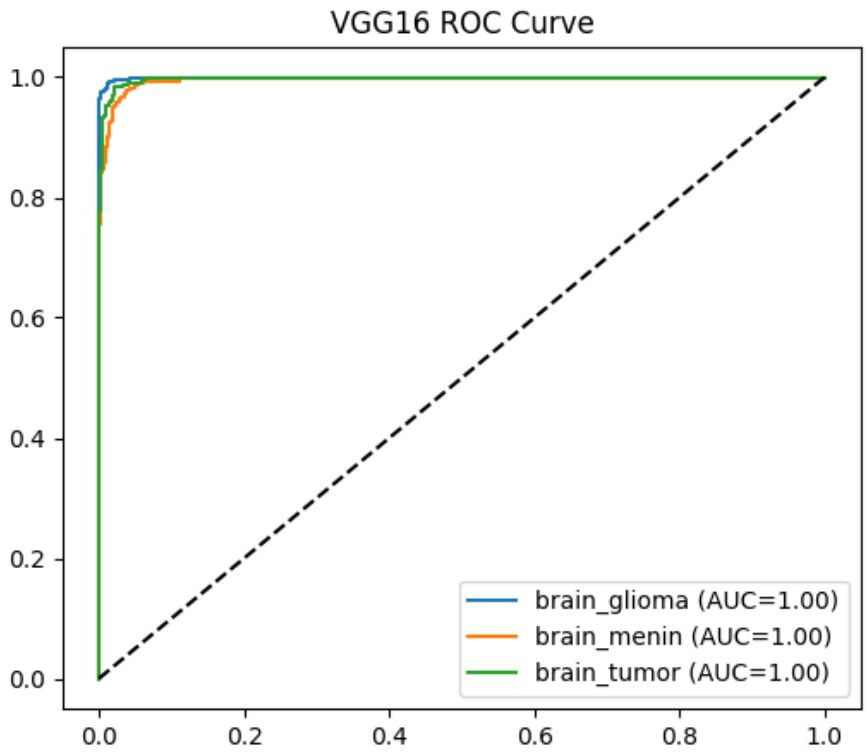

- Değerlendirme: VGG16, parametre sayısının fazlalığına rağmen kararlı bir eğitim süreci geçirmiştir. Özellikle tümörlü bölgelerin tespitinde yüksek duyarlılık göstermiştir.

4.4. VGG19 Modeli

VGG16'nın daha derin versiyonu olan bu model, katman sayısının artışının performansa etkisini gözlemlemek için kullanılmıştır.

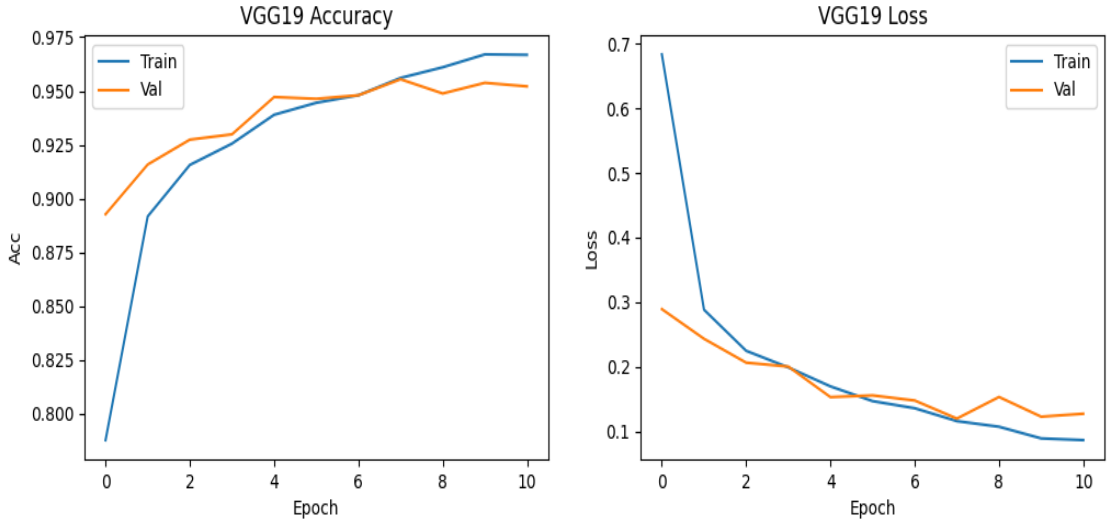

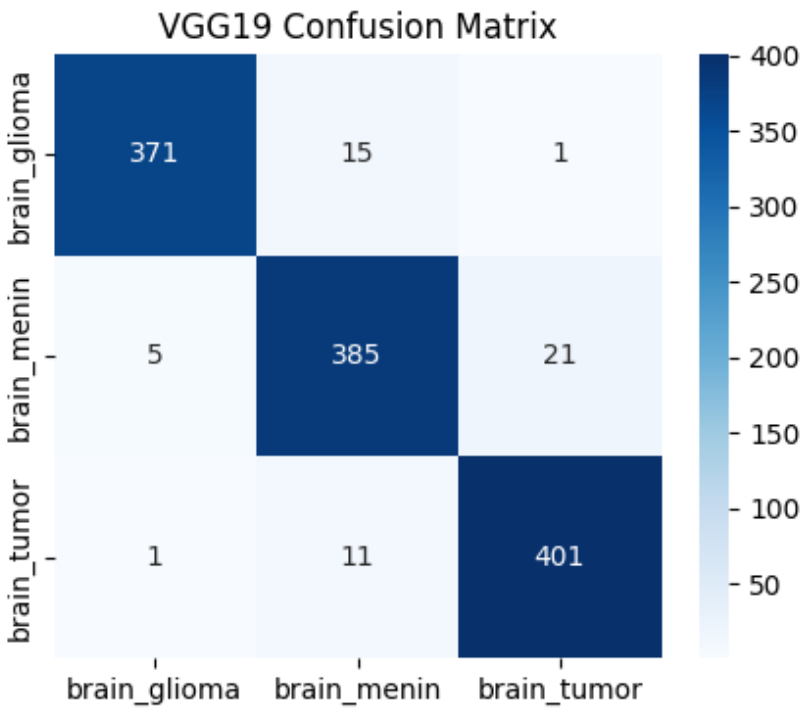

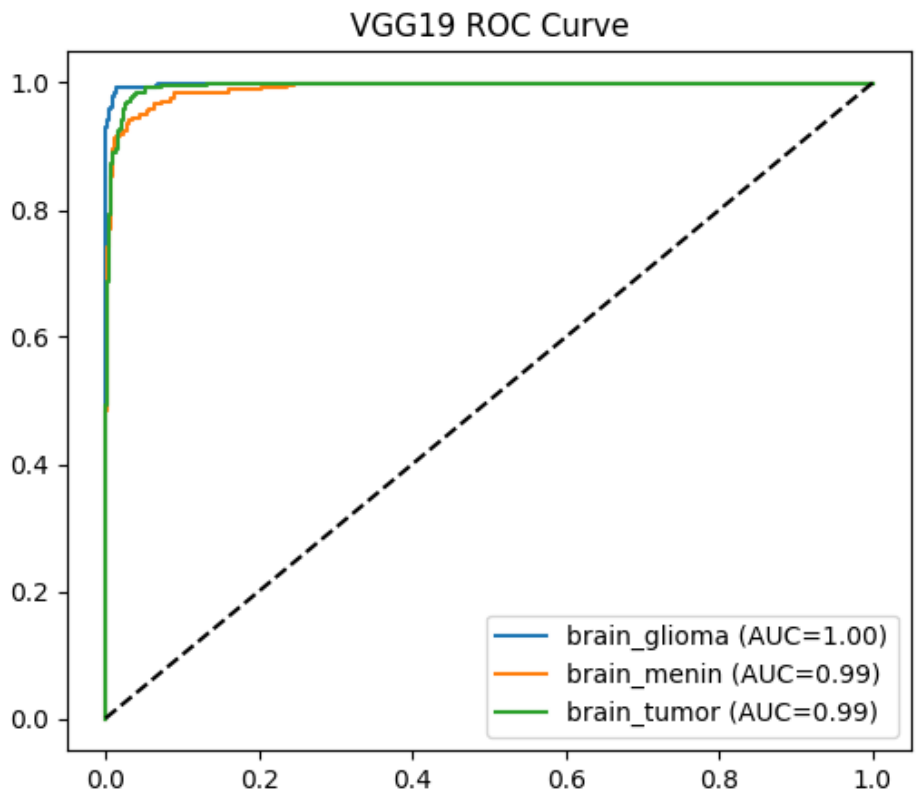

- Değerlendirme: Derinlik artışı, karmaşık desenlerin yakalanmasına katkı sağlamış, Confusion Matrix incelendiğinde sınıflar arası karışıklığın düşük olduğu gözlemlenmiştir.

4.5. ResNet50 Modeli

Artık (Residual) bağlantılar kullanan bu model, derin ağlarda yaşanan öğrenme kaybı sorununu çözme yeteneği ile analiz edilmiştir.

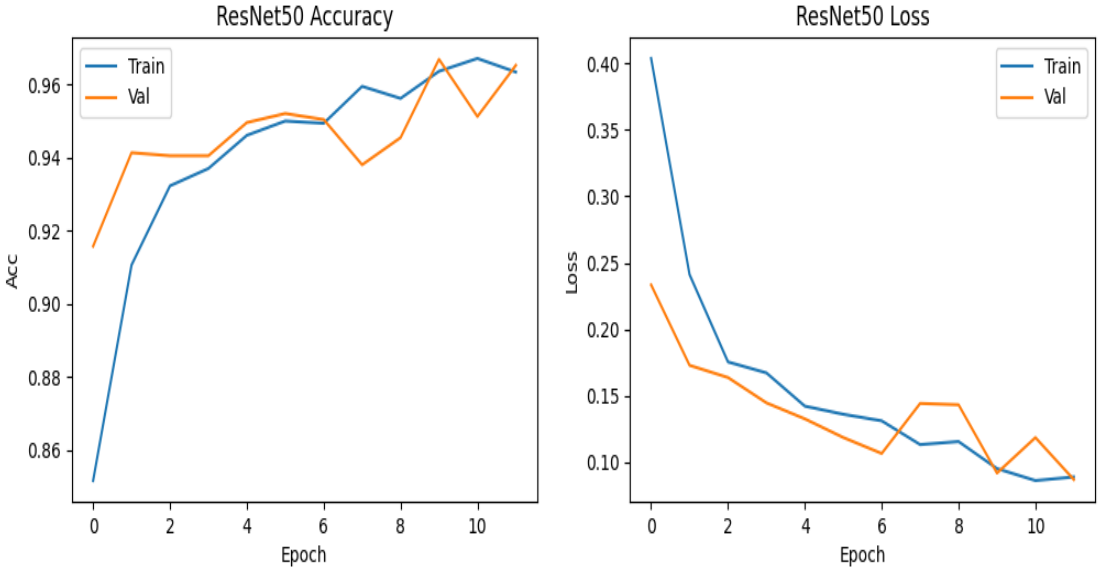

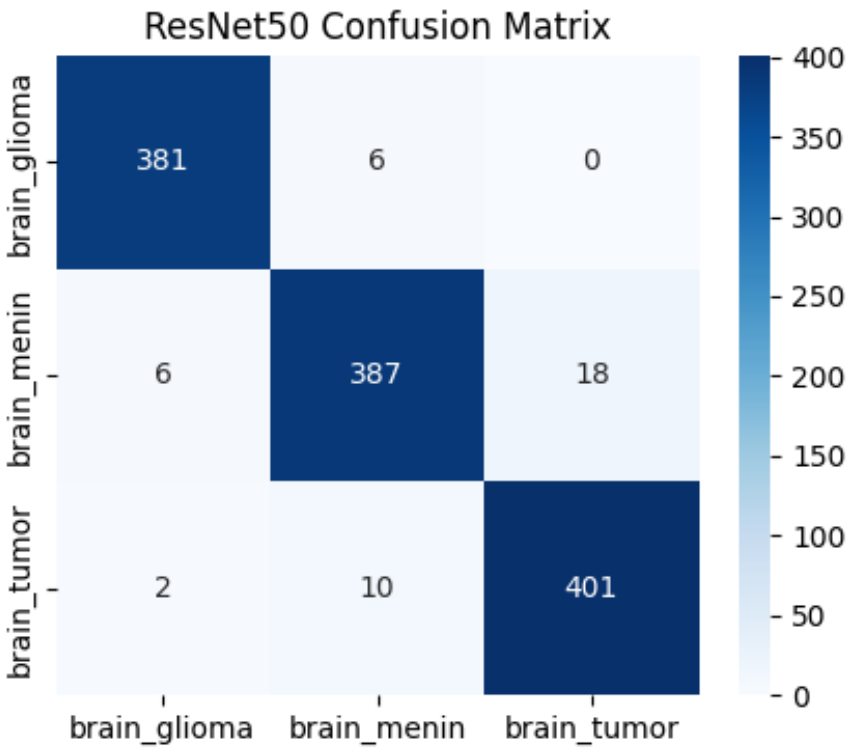
ResNet50 Confusion Matrix
brain_glioma
brain_menin
brain_tumor
381
6
0
6
387
18
2
10
401
brain_glioma
brain_menin
brain_tumor
400
350
300
250
200
150
100
50
0

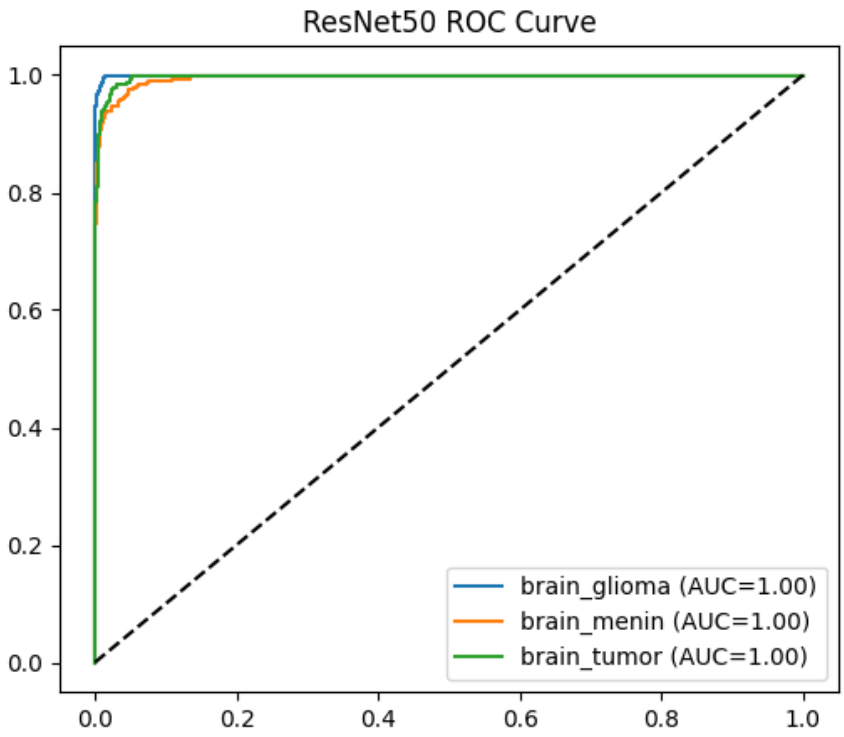
ResNet50 ROC Curve
1.0
0.8
0.6
0.4
0.2
0.0
0.0
0.2
0.4
0.6
0.8
1.0
brain_glioma (AUC=1.00)
brain_menin (AUC=1.00)
brain_tumor (AUC=1.00)

Değerlendirme: ResNet50, eğitim sürecinde oldukça stabil (kararlı) bir grafik çizmiştir. ROC eğrisinin yüksek AUC değeri, modelin güvenilirliğini kanıtlamaktadır.

4.6. MobileNetV2 Modeli

Hafif ve hızlı yapısıyla bilinen bu model, özellikle verimlilik açısından test edilmiştir.

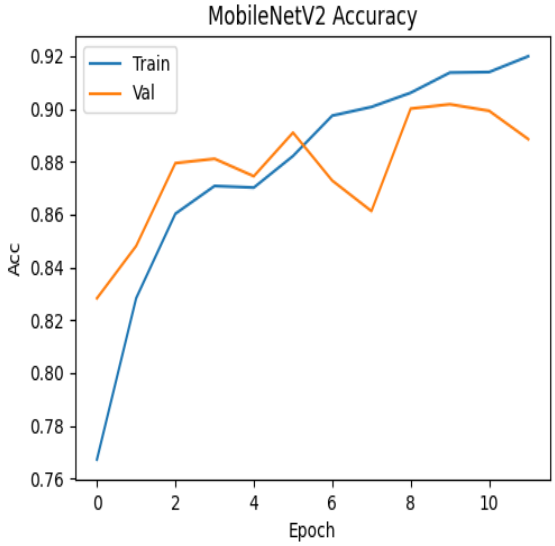

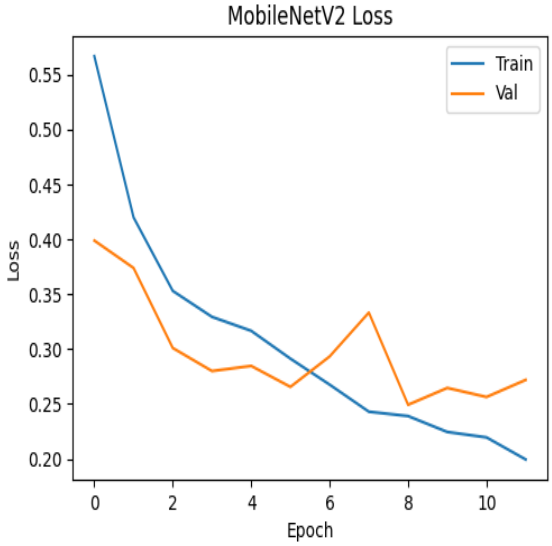

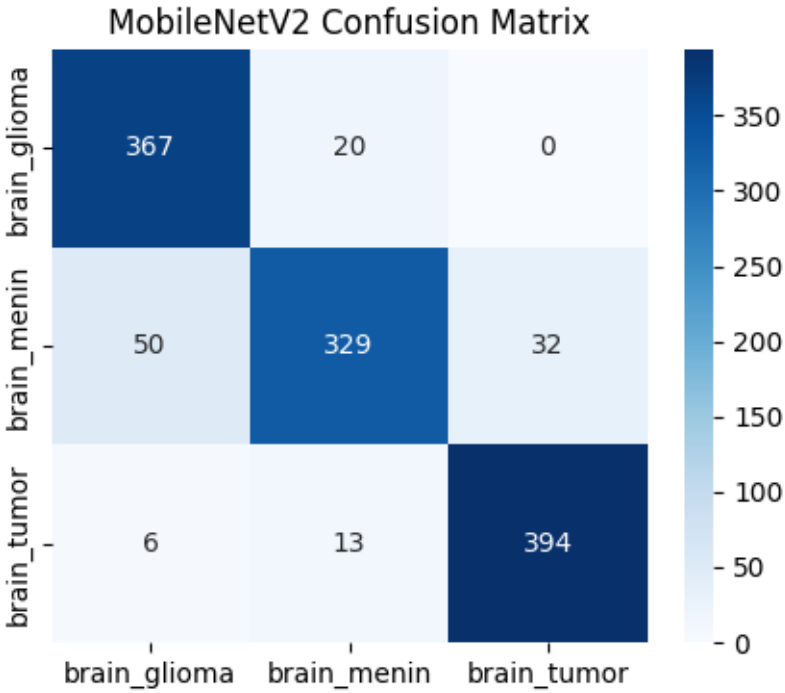

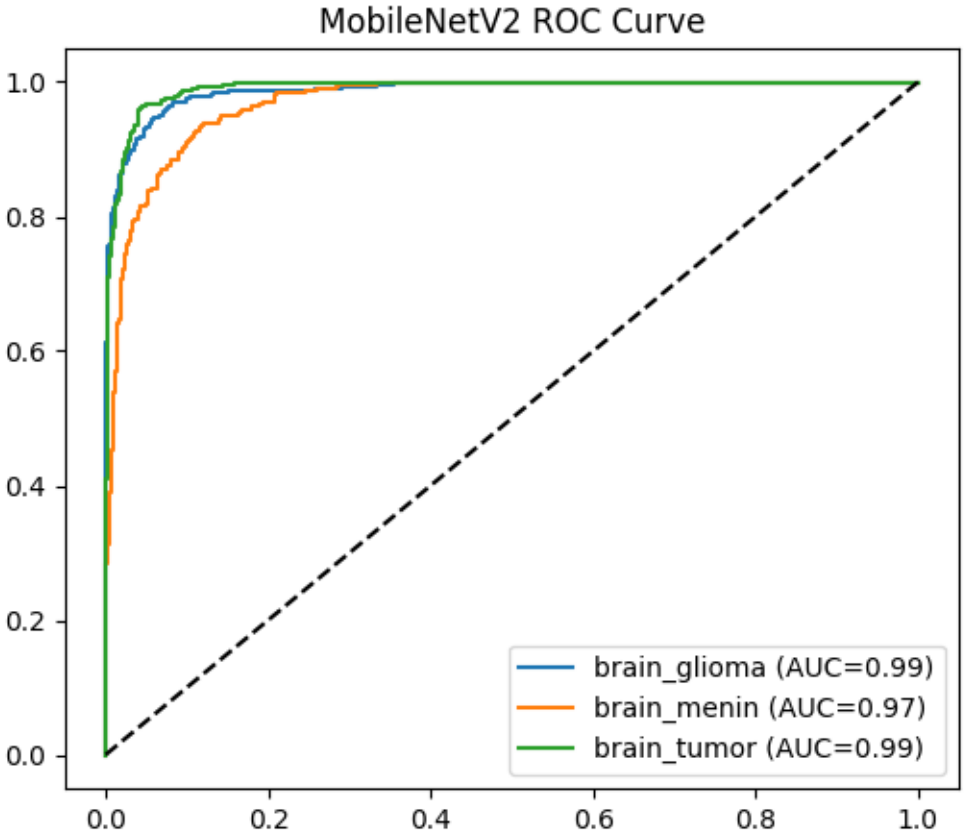

Değerlendirme: Düşük parametre sayısına rağmen şaşırtıcı derecede yüksek bir başarı elde etmiştir. Eğitim süresinin kısalığı ve yüksek doğruluğu, onu en verimli modellerden biri yapmaktadır.

4.7. InceptionV3 Modeli

Farklı boyutlardaki filtreleri paralel kullanarak (Inception modülleri) görüntüdeki detayları yakalamayı hedefleyen modeldir.

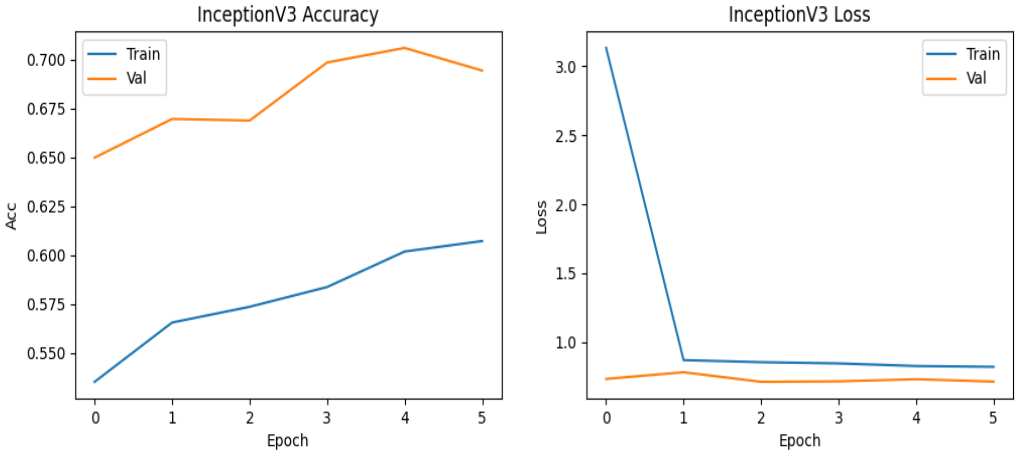

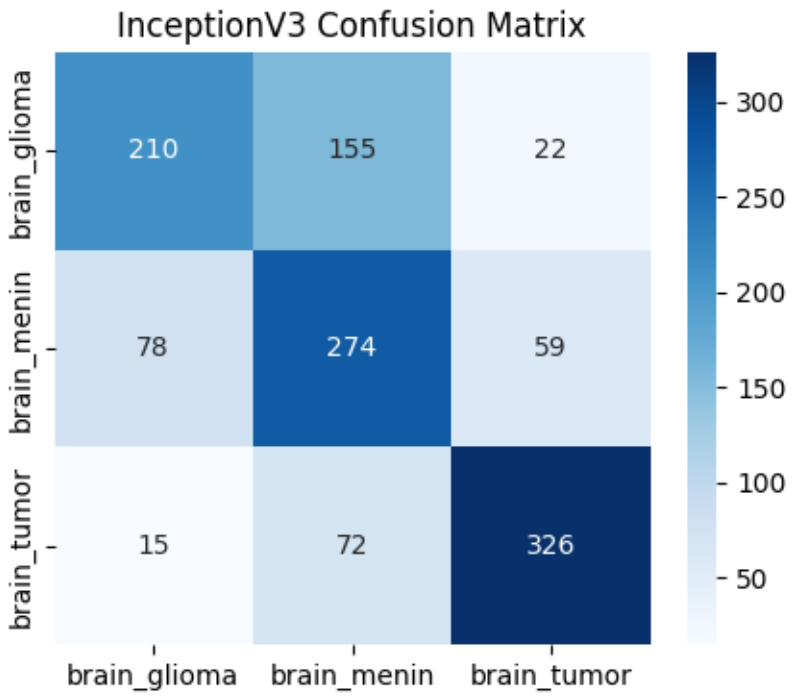

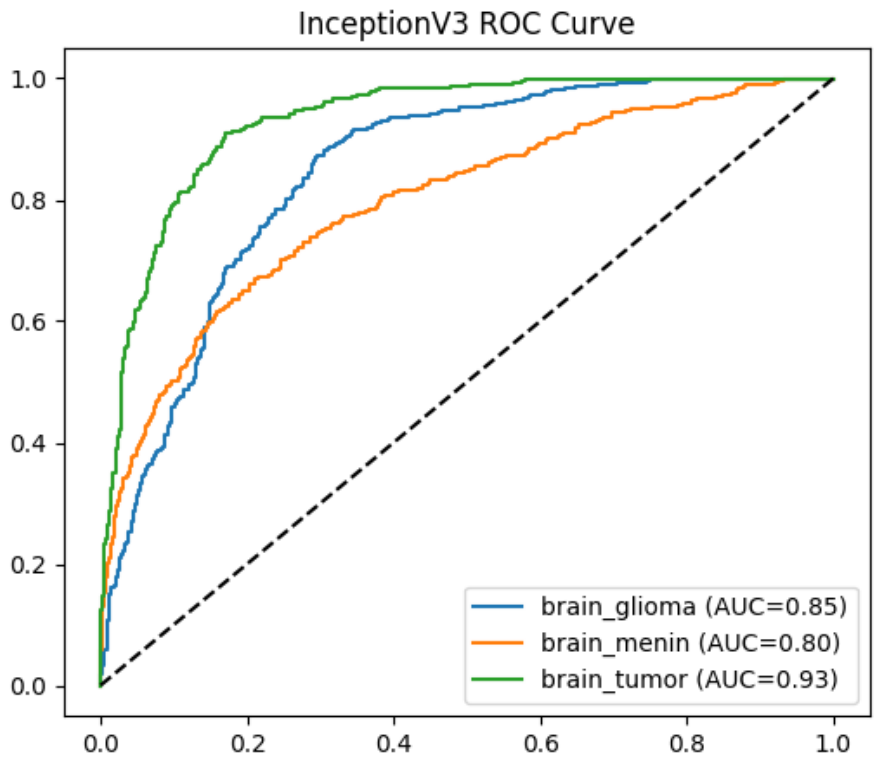

Değerlendirme: Görüntüdeki hem ince hem de kaba detayları yakalayabilmesi sayesinde sınıflandırma başarısı üst seviyelerde gerçekleşmiştir.

4.8. Xception Modeli

Inception mimarisinin daha gelişmiş, derinlemesine ayrılabilir konvolüsyonlar kullanan versiyonudur.

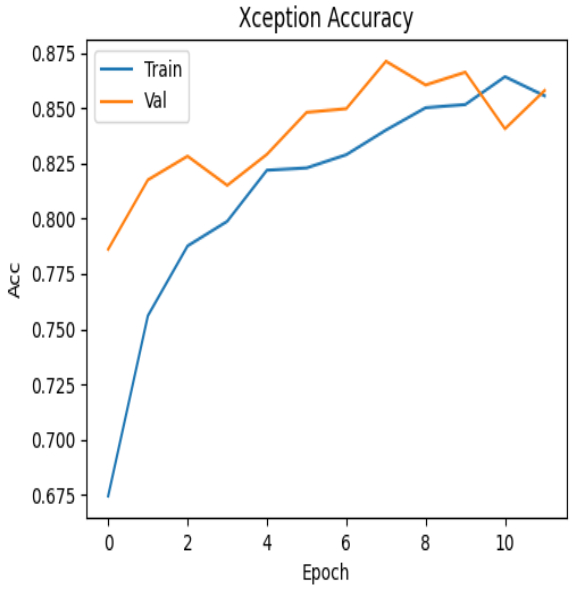

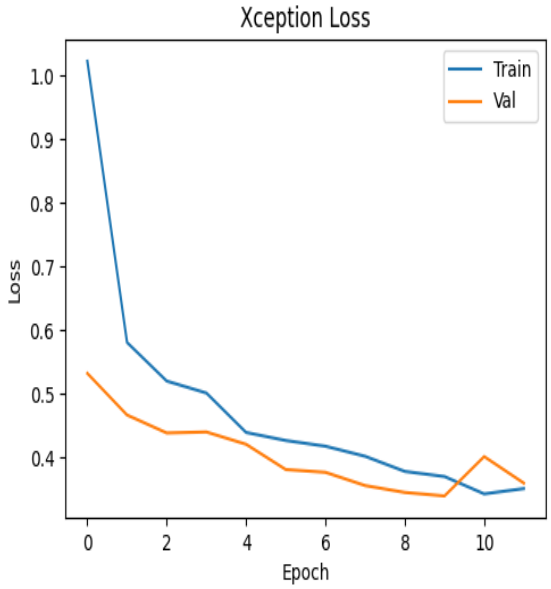

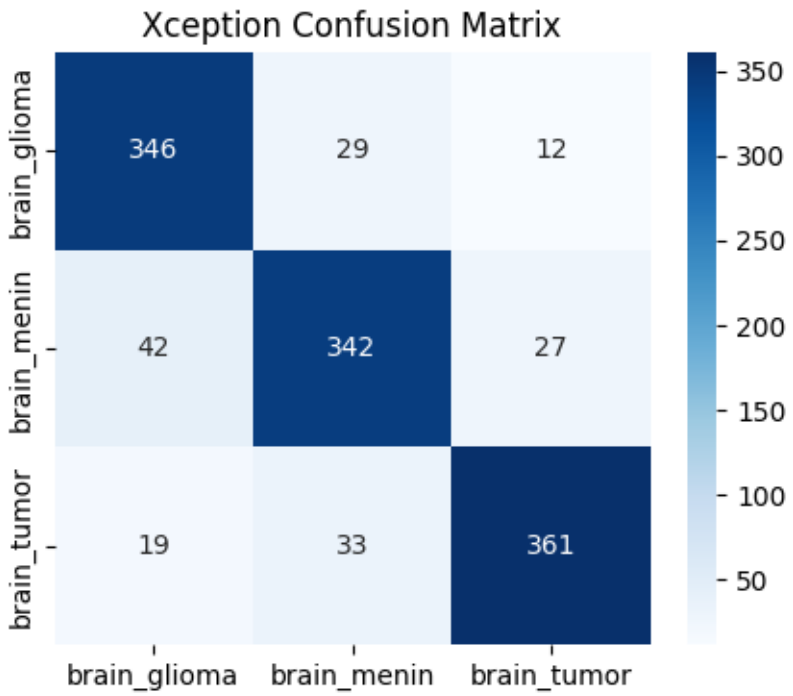

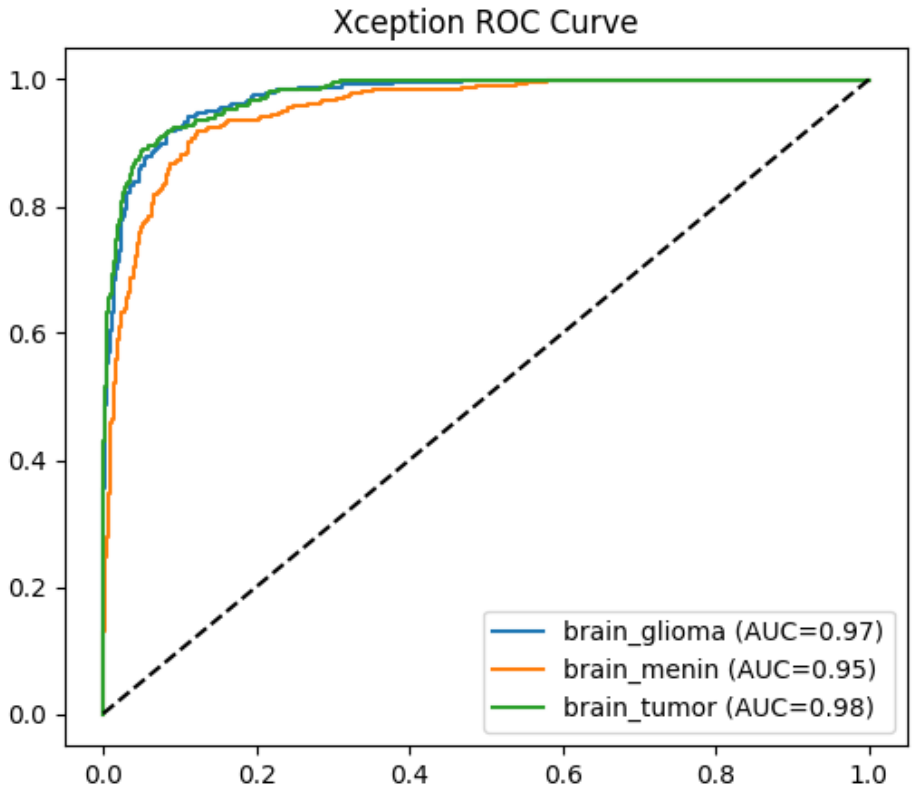

Değerlendirme: Mimari karmaşıklığına rağmen model, veri setimizdeki örüntüleri başarıyla öğrenmiş ve yüksek doğruluk oranlarına ulaşmıştır.

4.9. DenseNet121 Modeli

Katmanlar arası yoğun bağlantı (dense connection) kullanarak bilgi akışını güçlendiren bu model analiz edilmiştir.

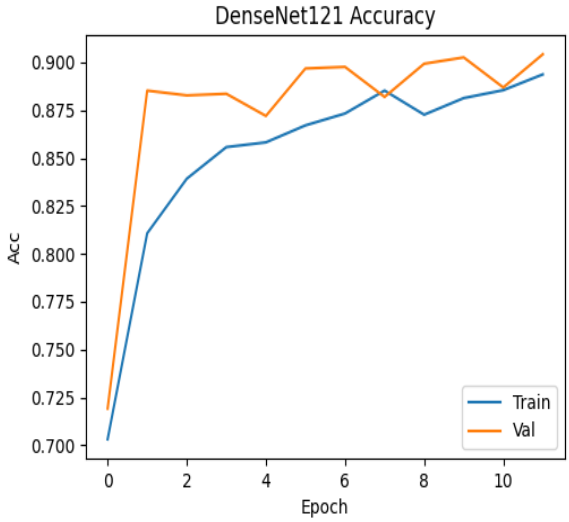

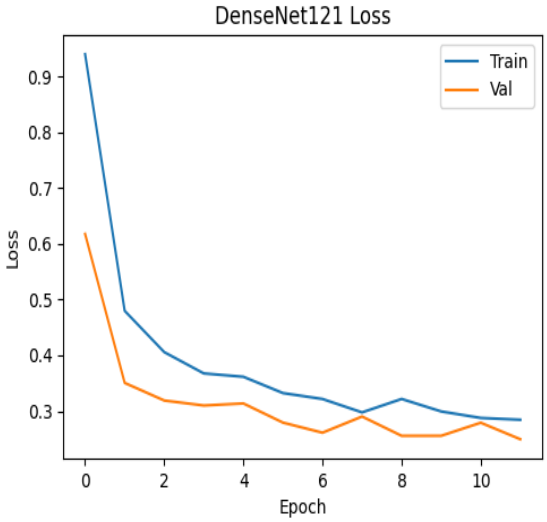

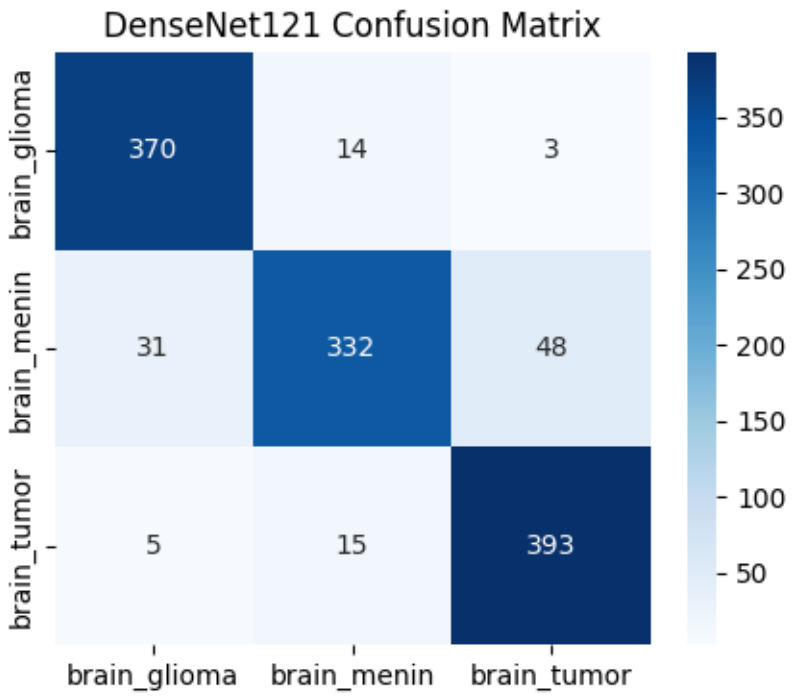
DenseNet121 Confusion Matrix
brain_glioma
brain_menin
brain_tumor
370
14
3
31
332
48
5
15
393
brain_glioma
brain_menin
brain_tumor
350
300
250
200
150
100
50

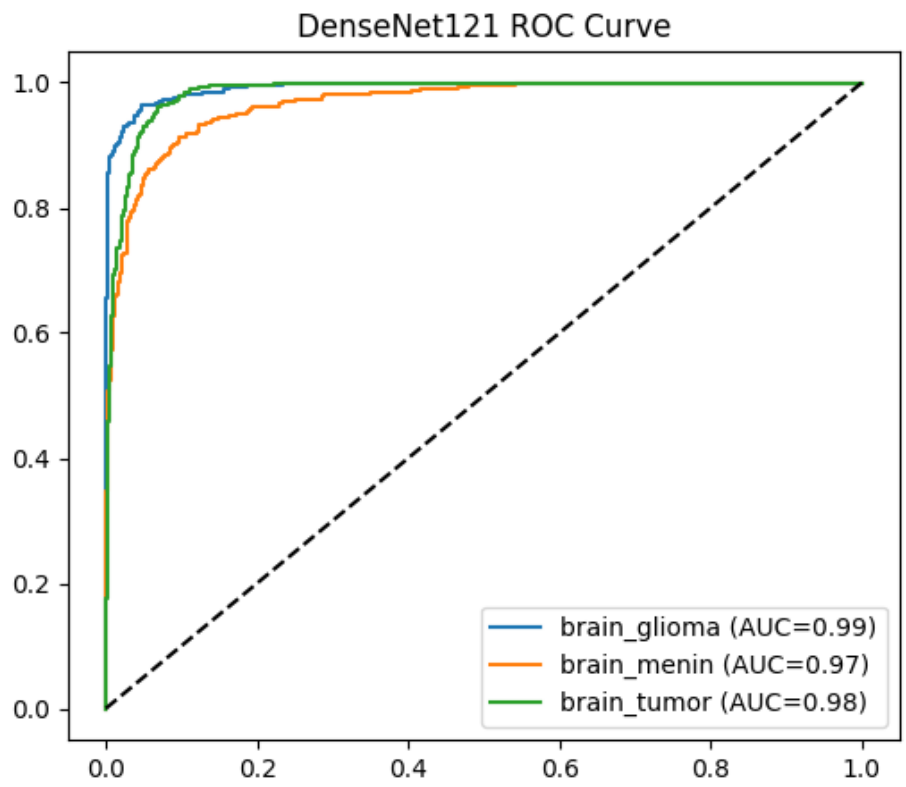
DenseNet121 ROC Curve
1.0
0.8
0.6
0.4
0.2
0.0
0.0
0.2
0.4
0.6
0.8
1.0
brain_glioma (AUC=0.99)
brain_menin (AUC=0.97)
brain_tumor (AUC=0.98)

Değerlendirme: Özellik tekrar kullanımı (feature reuse) sayesinde model, eğitim verisini çok verimli kullanmış ve yüksek genelleme yeteneği sergilemiştir.

4.10. EfficientNetB0 Modeli

Google tarafından geliştirilen, hız ve doğruluk dengesini optimize eden modern bir mimaridir.

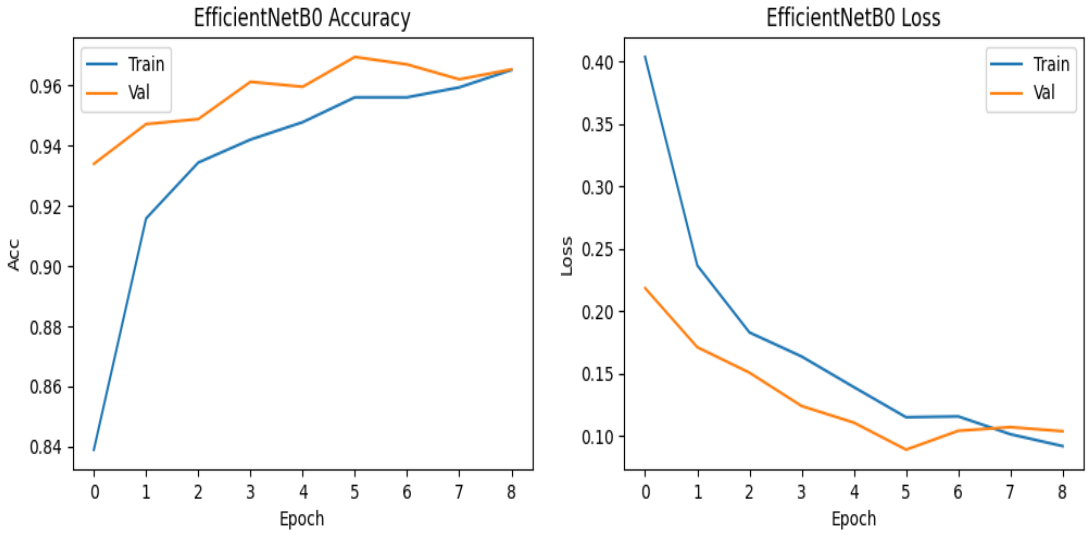

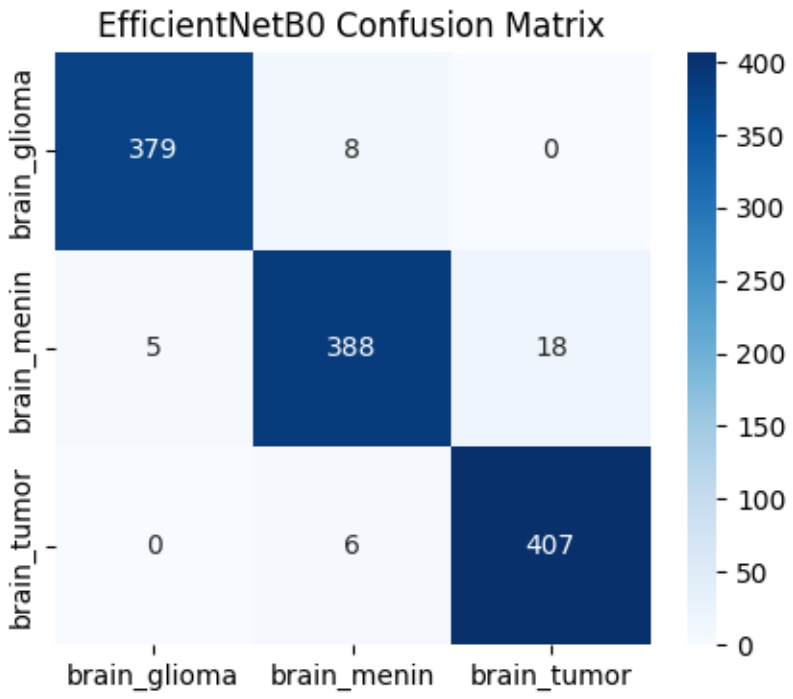

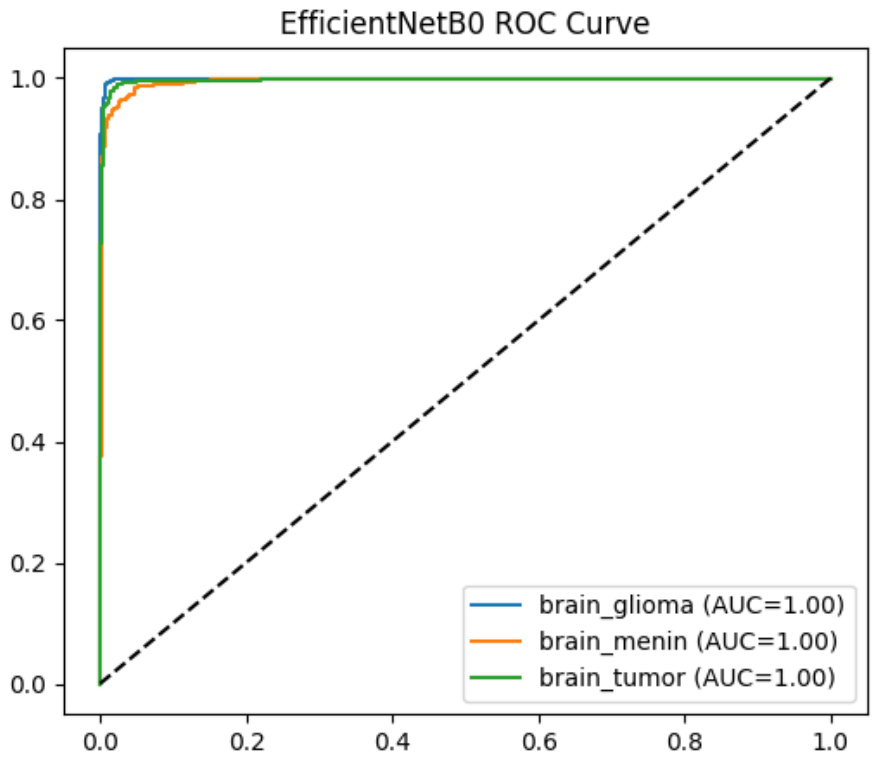

Değerlendirme: Model, optimize edilmiş yapısı sayesinde hem hızlı yakınsama (convergence) göstermiş hem de rekabetçi bir doğruluk oranına ulaşmıştır.

4.11. GENEL KARŞILAŞTIRMA VE SONUÇ TABLOSU

Yapılan tüm testler sonucunda, 10 farklı modelin performans metrikleri (Accuracy, Precision, Recall, F1-Score) aşağıdaki tabloda özetlenmiştir.

	Model	Accuracy	Precision	Recall	F1-Score
9	EfficientNetB0	0,969447	0,969933	0,969613	0,969663
2	VGG16	0,969447	0,970013	0,969567	0,969703
4	ResNet50	0,965318	0,965591	0,965682	0,965587
3	VGG19	0,955409	0,956272	0,955447	0,955758
8	DenseNet121	0,904211	0,905378	0,905144	0,903474
5	MobileNetV2	0,900083	0,900445	0,900934	0,898872
7	Xception	0,866226	0,866386	0,866755	0,86629
0	Custom_CNN_Simple	0,8109	0,819019	0,809581	0,811576
1	Custom_CNN_Deep	0,800991	0,803316	0,803215	0,798788
6	InceptionV3	0,668869	0,680319	0,666216	0,668232

Tablo Analizi: Tablo incelendiğinde, Transfer Learning yöntemlerinin genel olarak özgün (Custom) modellere göre daha yüksek başarı sağladığı görülmektedir. Bu durum, önceden eğitilmiş ağırlıkların (ImageNet) özellik çıkarımında sağladığı avantajı kanıtlamaktadır. Hız ve performans dengesi (Trade-off) açısından MobileNetV2 ve EfficientNetB0 öne çıkarken, mutlak doğruluk açısından derin mimarilerin başarısı dikkat çekicidir.

5. SONUÇ

Bu çalışma kapsamında, beyin MR görüntülerinden tümör tespiti için kapsamlı bir derin öğrenme analizi gerçekleştirilmiştir. Geliştirilen sistemde hem özgün mimariler hem de endüstri standardı modeller kullanılarak literatüre uygun bir kıyaslama yapılmıştır. Elde edilen sonuçlar, derin öğrenme tabanlı sistemlerin medikal görüntü analizinde radyologlara yardımcı bir karar destek mekanizması olarak kullanılabileceğini göstermektedir